针对行人重识别-学习多粒度判别性特征

GuanshuoWang1∗,YufengYuan2∗,XiongChen2,JiweiLi2,XiZhou1,2
Cooperative Medianet Innovation Center, Shanghai JiaoTong University
CloudWalk Technology
guanshuo.wang@sjtu.edu.cn,{yuanyufeng,chenxiong,lijiwei,zhouxi}@cloudwalk.cn

摘要：

全局特征和局部特征的结合是提高行人重识别任务识别性能的重要途径。此前的基于分块的方法主要集中于定位具有特定预定义语义的区域来学习局部特征表示。这种方法增加了学习难度，但对于存在较大变化的场景，这种方法不够高效和鲁棒。这篇论文里，我们提出了一种端到端的多粒度判别性特征学习策略。我们精心设计了多粒度网络(MGN): 一种多分支的深度网络结构，包括一个分支用于全局特征表示，两个分支用于局部特征表示。替代学习语义区域，我们把图像均匀划分为一些水平条，通过改变不同的局部分支水平条的个数来获得多粒度的局部特征表示。在主流评估数据集（包括 Market-1501、DukeMTMC- reid 和 CUHK03）中进行的综合实验表明，我们的方法均取得了最优性能，并且远超过当前最优方法。例如，在 Market-1501 数据集单查询模式下，结合重新排序方法，我们的方法取得了 rank1/map=96.6%/94.2%的最佳结果。

关键词：行人重识别、特征学习、多分支网络结构

1 介绍

行人重识别是一项具有挑战性的任务，它旨在从不同监控摄像头所捕获的行人数据库中检索出给定的行人。由于监控视频图像的场景复杂性，行人重识别面临的主要挑战来自于行人的姿态、遮挡、衣服、背景杂波、检测失败等大的变化，而深度卷积神经网络的成功为行人重识别带来更强大的特征表示能力。近年来，行人重识别 [4,5,22,27,29,30,36]在识别率（Rank1-Accuracy）和平均精度（Map）上取得了巨大突破。

行人表示的直观方法是从全身提取判别性特征。全局特征学习的目的是捕捉最显著的线索来代表不同行人的身份。然而，监控场景中捕获的图像的高复杂性通常限制了大规模行人重识别场景中特征学习的准确性。由于行人重识别数据集的规模有限、多样性弱，一些非显著或不经常出现的细节信息在全局特征学习过程中，容易被忽略，对识别没有贡献，使得全局特征难以适应相似的类间共性或较大的类内差异。

为了解决这一难题，在许多以前的论文中，从图像中定位重要的身体部位来表示身份的局部信息已被证实是提高识别准确度的有效方法。每个被定位的身体部位区域仅包含来自全身的少量局部信息，同时通过定位操作过滤区域外其他相关或无关信息的干扰，从而学习局部特征，使局部特征更多地关注于身份，并将其作为全局特征的重要补充。基于区块的方法根据其区块定位可分为三个主要途径：1）定位具有较强结构信息的区域，如人体经验知识[8、21、36、43]或基于学习的姿势信息[33、44]；2）通过区域建议方法定位部分区域[19，41]；3）通过注意力机制加强特征学习 [22，24，25，45]。然而，明显的局限性阻碍了这些方法的有效性。首先，姿势或遮挡变化会影响局部表示的可靠性。其次，这些方法几乎只关注具有固定语义的特定部分，而不能涵盖所有的判别信息。最后，这些方法大多不是端到端的学习过程，增加了特征学习的复杂性和难度。

本文提出了一种将不同粒度的全局信息和局部信息相结合的特征学习策略。如图 1 所示，不同数量的分区条引入了内容粒度的多样性。我们定义最粗糙的粒度为包含全局信息的原始图像，并且随着分区数量的增加，局部的特征可以更多地集中在每个部分条带中更细粒度的判别性信息上，并过滤其他条带上的信息。由于深度学习机制可以从整个图像中捕获不同程度的响应，因此从较小的部分区域提取的局部特征能捕获更细粒度的特征。请注意，这些部分区域不需要定位具有特定语义的分区，而只需要在原始图像上放置一块等分条带。通过观察，我们发现，随着水平条纹数量的增加，识别响应的粒度确实变得更细。基于这一动机，我们设计了多粒度网络（MGN），一种多分支网络结构，从 ResNet-50[13]主干的第 4 个阶段开始，将多分支网络结构分为一个全局分支和两个局部分支，并对其参数进行了细化。在 MGN 的每个局部分支中，我们将全局平均池化特征映射划分为不同数量的条带作为区块特征，以独立地学习局部特征表示，参考[36]中的方法。

与以前的基于区块划分的方法相比，我们的方法只使用等分的区块进行局部特征表示，但比以前的所有方法都能获得优异的性能。此外，我们的方法完全是一个端到端的学习过程，易于学习和实现。大量的实验结果表明，我们的方法可以在多个主流 Re-ID 数据集上实现最先进的性能，即使不利用没有任何额外的外部数据或重新排序[50]操作的设置也是如此。

图 1：身体区块划分从粗粒度到细粒度。我们将整个身体的原始行人图像视为左栏中最粗的粒度。条带图像划分的越多，分区的粒度就越大。

2 相关工作

随着深度学习的蓬勃发展，基于深度网络的特征学习已成为行人重识别任务的一种常见做法。[20，42]首先将深度孪生网络引入 Re-ID，并结合身体部位特征学习，与基于人工设计特征的方法相比，获得更高的性能。[47]提出了以 ResNet-50 为主干网络的 IDE 作为现代 Re-ID 系统性能水平基准线。在[1，37]中，利用精心设计的机制，计算了图像对的中层特征，描述了局部部件之间的相互关系。[39]引入了跨域学习，以增强不同领域行人场景的泛化能力。[50]将重新排序策略引入重新排序任务，以修改排序结果以提高准确性。

近年来，一些深度 RE-ID 方法将系统的性能提升到了一个新的水平。[43]在训练阶段引入了基于区块的对齐匹配，通过最短路径规划和对偶学习来提高度量学习性能。[3，36]两者都将输入图像的特征图在垂直方向等分为多个条纹。[3]将局部特征切片与 LSTM 网络合并，并结合从分类度量学习中学习到的全局特征。相反，[36]直接将来自本地区块的特征作为最终特征连接起来，并应用改进的区块池化来修改特征。然而，根据[43]中的报告，这些系统只是达到了与人类相似的性能，我们仍需要走很长一条路来超越它

在所有的性能改进策略中，我们认为结合局部图像表示是最有效的。如第一节所述，我们总结了基于零件的学习的三个主要途径：根据人体的结构信息确定区域，通过区域建议方法定位身体零件，通过空间注意增强特征。在[8，21，36]中，根据人体固有的结构知识，图像在水平方向上被分成若干条条纹，在此基础上学习局部特征表示。[33，44]利用姿态估计器预测的人体关节点，裁剪出更精确的具有语义的区域。为了在不使用强化学习下定位语义分区，在一些基于部分的方法中，采用了区域建议方法，如[11，18]等[19，22，25，41，45]。注意力机制对特征提取尤其重要，特征在[22，24，25]中得到了增强。我们所提出的方法只使用简单的水平条作为局部特征学习的部分区域，但取得了优异的性能。

在特征学习中，损失函数被用作监督信息。在深度 Re-ID 系统的训练阶段，最常见的损失函数是分类损失和度量损失。Softmax loss 几乎是分类损失函数的唯一选择，因为它对各种多类分类任务具有很强的鲁棒性，可以单独使用[1、19、22、25、36、39、41、47] 或与其他损失[3，8，20，43]结合在 Re-ID 的嵌入学习过程中。对于度量损失，存在更多损失函数。在孪生网络[37]中，Contrastive loss [12]通常被使用，它关注于最大化类间对之间的距离和最小化类内对之间的距离。Triplet loss [15，28] 对同一锚样的正样本距离和负样本距离强迫学习一个界限。基于 Triplet loss，提出了许多变体[6、8、14、32]来解决度量学习中的学习或性能问题。在所提出的方法中，我们采用了同时具有 SoftMax 和 Triplet 损失的联合学习。

3 多粒度网络

图 2 显示了从 IDE 基线模型[47]中提取的特定图像和基于 IDE 的部分模型的特征响应图。我们可以观察到，即使没有明确的注意机制来增强对某些重要成分的偏好，深层网络仍然可以根据其固有的语义意义，初步了解不同身体部位的反应偏好。然而，为了消除高复杂度行人图像中不相关模式的干扰，更高的响应只集中在步行者的主体上，而不是任何具体的具有语义模式的身体部位。当我们缩小代表区域的范围并训练为一个分类任务来学习局部特征时，我们可以观察到局部特征图上的响应开始聚集在一些显著的语义模式上，这些语义模式也随着代表区域的大小而变化。

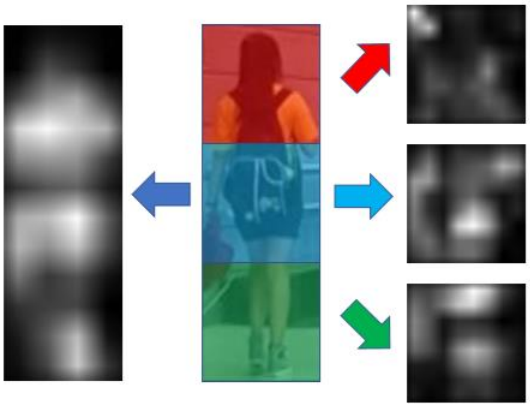

图 2 从不同模型的最后一个输出中提取不同粒度的特征响应图。响应强度由特征向量的 L2 范数所确定

3.1 网络结构

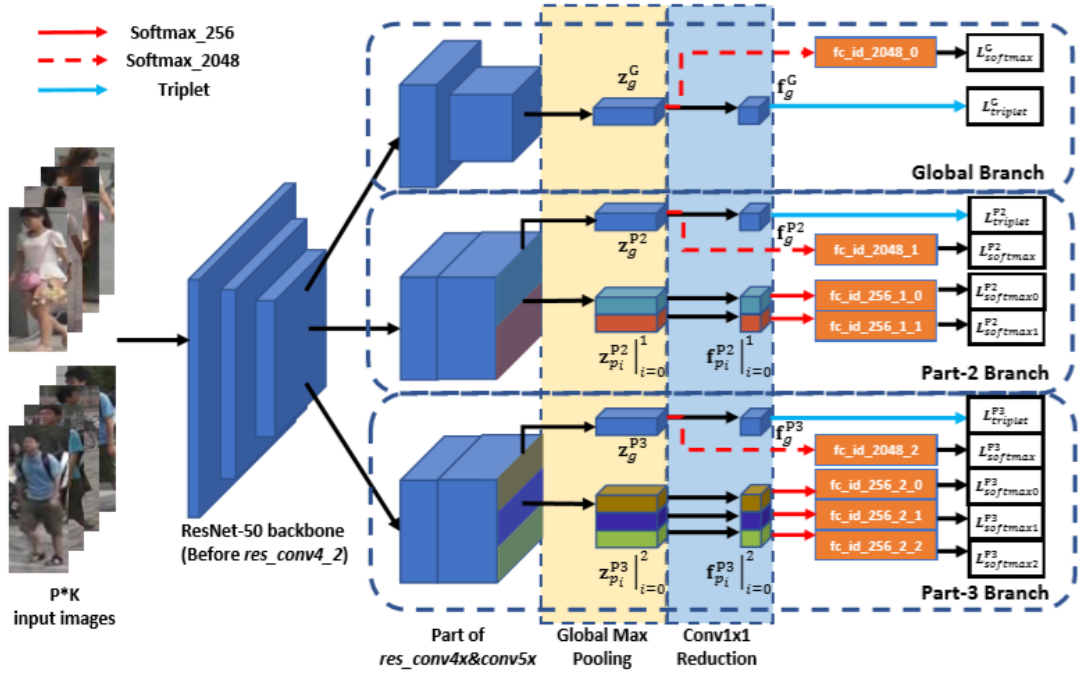

图 3 多粒度网络体系结构。Resnet-50 主干在 Res-Conv4-1 剩余块后分成三个分支：全局分支、第二部分分支和第三部分分支。在测试过程中，所有维度缩减的特征作为行人图像的最终特征表示连接在一起。注意，用于维度缩减的 1x1 卷积和用于预测的全连接层在每个分支中不共享权重。

多粒度网络的结构如图 3 所示，骨干网络采用 ResNet-50，最明显的修改是我们把 res_conv4_1 block 之后划分为 3 个独立的分支。

表 1 MGN 三条支路参数设置，原始输入图片尺寸 384X128

Branch	Part No.	Map Size	Dims	Feature
Global	1	12×4	256	f_g^G
Part-2	2	24×8	256*2+256	$\{\mathrm{f}_{p_i}^{P2}\|_{i=0}^{1}\}, \mathrm{f}_g^{P2}$
Part-3	3	24×8	256*3+256	$\{\mathrm{f}_{p_i}^{P3}\|_{i=0}^{2}\}, \mathrm{f}_g^{P3}$

表 1 显示了 MGN 三条支路的参数设置，在全局分支，我们在 res_coonv5_1 采用了 2 倍的下采样，接着采用了 GMP，接着是用于维度缩减的 1X1 的卷积层和 BN 层，最后是全连接层。

在测试阶段，为了获得最强大的识别能力，将所有减少到 256 dim 的特征作为最终特征串联起来，将全局和局部信息结合起来，以完善所学特征的综合性。

3.2 损失函数

为了充分发挥这个网络的表示学习的能力，我们采用了 Softmax Loss 用于分类，采用 Triplet Loss 用于度量学习。

对于基本的判别式学习而言，我们把识别问题视为多分类问题，对于第 i-th 学习的特征

f_i，Softmax Loss 被公式化为:

$$L_{soft\max} = -\sum_{i=1}^{N} \log \frac{e^{W_{y_i}^T f_i}}{\sum_{k=1}^{C} e^{W_k^T f_i}} \tag{1}$$

W_k 对应着第 k 类的权重向量，mini-batch 的大小是 N ,训练集的类别数目是 C ，不同于传统的 Softmax Loss，我们没有增加偏置项。在所有学习到的特征嵌入中，我们对所有分支的 2048-d 的全局特征向量和 256-d 的局部特征向量采用了 Softmax Loss。

所有全局特征向量经过维度衰减后 256-d 的特征向量使用 Triplet Loss 来进行训练，我们采用难样本挖掘损失函数，这个损失函数可以形式化为：

$$L_{triplet} = -\sum_{i=1}^{P} \sum_{a=1}^{K} [\alpha + \max_{p=1,\ldots K} \| f_a^{(i)} - f_p^{(i)} \|_2 - \min_{\substack{n=1\ldots K \\ j=1\ldots P \\ j\neq i}} \| f_a^{(i)} - f_n^{(j)} \|_2]_+ \tag{2}$$

在这里 $f_a^{(i)}, f_p^{(i)}, f_n^{(i)}$ 分别是指从锚点，正样本和负样本中提取出的特征向量，α 是控制类间与类内距离的超参数，这里正负样本是指与锚具有相同或不同身份的行人。候选的 Triplet 是由距锚点最远的正样本对和最近的负样本对以及锚点构成。也就是说，在一个小批量中最难的正负对，锚点由 P 个不同 id 和每个 id 的 K 个实例所组成。

在 MGN 架构中，为了避免损失权重调整的麻烦和收敛的困难，我们提出了度量前分类架构，它将 SoftMax 损失应用于第 2 部分和第 3 部分分支中 256-dim 局部特征以及所有分支 2048- dim 全局特征，将 Triplet Loss 应用于所有分支中 256-dim 全局特征。这种设置是从粗到细的机制中得到启发的，将非约化特征视为粗粒度信息来学习分类，将约化特征视为细粒度特征来学习度量的精细信息。与在相同的降维特征水平上施加联合效应相比，该方法具有较强的收敛性。此外，我们在局部特征上不使用 Triplet Loss。由于不对齐问题，局部区域的内容可能会发生很大的变化，这使得 Triplet Loss 在训练过程中容易不收敛。

3.3 讨论

在我们提出的多粒度网络体系结构中，有一些问题值得我们单独讨论。在本段中，我们具体讨论了以下问题：

根据我们设计 MGN 架构的最初动机，在一个分支中学习全局和局部表示似乎是合理的。我们可以直接将 Res-Conv5-U3 提取的相同的最终特征图分割成不同数量的条纹。但是，我们发现此设置对于进一步提高性能是无效的。借用[34]中的观点，原因可能是共享类似网络架构的分支（主要是 resnet-50 的第四个剩余阶段）只是对图像上不同级别的详细信息做出响应。一个混合单分支的多个粒度的学习特征可能会削弱详细信息的重要性。此外，我们尝试将主干网分成较浅或较深的层，但也没有取得更好的性能。

在我们的网络结构中，粒度的多样性三个分支实际上学习了表示不同性能的信息。具有较大感受野和全局最大池化的全局分支从行人图像中捕获完整但粗糙的特征，并且由第 2 部分和第 3 部分分支学习的特征没有跨步卷积和条纹的分割部分趋向于局部但精细。具有更多分区的分支将学习更精细的行人图像表示。学习不同偏好的分支可以协同地向公共主干部分补充低级的识别信息，这是任何一个分支提高性能的原因。

4 实验

4.1 实现细节

为了从行人图像中获取更详细的信息，我们参考[36]并将输入图像的大小调整为384X128。我们使用在 imagenet[9]上预先训练的 resnet-50 的权重来初始化 MGN 的主干和分支。注意，在 res_conv4_1 块之后，网络中的不同分支都用相应层的相同预训练权重初始化。在训练阶段，我们只部署随机水平翻转训练数据集中的图像以进行数据扩充。为配合 Triplet Loss 的要求，从训练集中随机抽 P 个 id 和从每个 id 中抽取 K 个样本，对每个小批量进行抽样。在这里，我们建议设置 p=16 和 k=4 来训练我们提出的模型。对于 Triplet Loss 的间隔参数，我们在所有实验中都设定为 1.2。我们采用动量为 0.9 的 SGD 优化器。L2 正则化的权重衰减系数设置为 0.0005。对于学习率策略，我们将初始学习率设置为 0.01，经过 40 和 60 个阶段的训练后，学习率降低到 1e-3 和 1e-4。整个训练过程持续 80 个阶段。在评估阶段，我们都提取了与原始图像和水平翻转版本相对应的特征，然后将这些特征的平均值作为最终特征。我们的模型是在 pytorch 框架上实现的。要在 Market-1501 数据集上执行完整的训练过程，需要两个 Nvidia Titan XP GPU 进行数据并行加速约 2 小时。我们对不同数据集的所有实验都遵循上面的设置。

4.2 数据集和测试协议

我们在三种主流的 Re-ID 数据集：Market-1501[46]、DukeMTMC-Reid[49]和 CUHK03[20]对我们提出的方法进行了评估实验。在展示我们的结果之前，有必要介绍这些数据集及其评估协议。

Market-1501：该数据集包括从 6 个不同摄像机拍摄的 1501 人的图像。行人被裁成由 DPM 探测器预测的边界框[10]。整个数据集分为训练集：共 12936 幅 751 人的图像，测试集：共 3368 幅查询图像，19732 幅 750 人的图库图像。评价有单查询和多查询两种模式，这两种模式所不同的是同一身份的图像数量。在多查询模式下，从同一台相机拍摄的人的图像中提取的所有功能都由 AVG 或 MAX 池化合并，其中包含更完整的信息，想比于只有 1 个查询图像的单一查询模式。

DukeMTMC REID：此数据集是 Dukemtmc 的一个子集[26]。它由 8 台高分辨率相机拍摄的 1812 人的 36411 张照片组成。从数据集中随机抽取 702 人的 16522 幅图像作为训练集，剩余 702 人分为测试集，测试集包含 2228 幅查询图像和 17661 幅画廊图像。这可能是目前最具挑战性的人脸识别数据集，常见的情况是人与人之间具有高度的相似性，在同一身份中存在较大的差异。

CUHK03：这个数据集由 14097 张图片组成，每个孩子有 1467 张，来自 6 个摄像头。此数据集中提供了两种类型的注释：手动标记的行人边界框和 DPM 检测到的边界框。最初，整个数据集被分为 20 个随机分割进行交叉验证，这是为手工制作的方法而设计的，并且对基于深度学习的方法进行实验非常耗时。

Protocols:在实验中，为了评估 RE-ID 方法的性能，我们报告了所有候选数据集在 Rank1,Rank5 和 Rank10 的累积匹配特性（CMC）和平均精度（MAP）。在 Market-1501 数据集上，我们在单查询和多查询模式下进行了实验。在 CUHK03 数据集上，为了简化评估程序，同时提高结果反映的性能的准确性，我们采用了[50]中使用的协议。

4.3 与当前最优方法的比较

我们将所提出的方法与所有候选数据集上当前最先进的方法进行了比较，以显示我们相对于所有现有竞争对手的显著性能优势。具体结果如下：

Market-1501：如表 2 所示。根据是否实施重新排序，将结果分为两组。在单查询模式下，PCB+RPP [36] 通过重新排序获得了最好的结果，但我们的 MGN 达到了 rank-1/map=95.7%/86.9%，比以前的方法在 rank-1 精度上高出 1.9%，在 map 上高出 5.3%。重新排序后的结果可以提高到 rank-1/map=96.6%/94.2%，大大超过了现有方法。

图 4 显示了一些给定查询行人图像的前 10 个排名结果。前两个结果显示出很强的鲁棒性：无论这些被捕获的行人的姿势或步态如何，MGN 特征都能有力地代表他们身份的识别信息。第三个查询图像在低分辨率条件下捕获，丢失大量重要信息。然而，从一些细节线索，如包的带子和他的黑色西装，大多数排名结果是准确的。最后一位行人背着一个黑色的背包，但我们可以在 3、6 和 9 级的前视图中获得他拍摄的图像。我们将这个令人惊讶的结果归因于局部特征的影响，当一些显著的部分丢失时，这些特征就建立了关系。

Methods	Single Query		Multiple Query	
	Rank-1	mAP	Rank-1	mAP
TriNet[14]	84.9	69.1	90.5	76.4
JLML[21]	85.1	65.5	89.7	74.5
AACN[40]	85.9	66.9	89.8	75.1
AOS[16]	86.5	70.4	91.3	78.3
DPFL[7]	88.6	72.6	92.2	80.4
MLFN[4]	90.0	74.3	92.3	82.4
KPM+RSA+HG[30]	90.1	75.3	-	-
PSE+ECN[27]	90.4	80.5	-	-
HA-CNN[22]	91.2	75.7	93.8	82.8
DuATM[31]	91.4	76.6	-	-
GSRW[29]	92.7	82.5	-	-
DNN_CRF[5]	93.5	81.6	-	-
PCB+RPP[36]	93.8	81.6	-	-
MGN(Ours)	**95.7**	**86.9**	**96.9**	**90.7**
TriNet(RK)[14]	86.7	81.1	91.8	87.2
AOS(RK)[16]	88.7	83.3	92.5	88.6
AACN(RK)[40]	88.7	83.0	92.2	87.3
PSE+ECN(RK)[27]	90.3	84.0	-	-
MGN(Ours, RK)	**96.6**	**94.2**	**97.1**	**95.9**

表 2 将 market-1501 的结果与单查询设置（SQ）和多查询设置（MQ）进行比较。”“RK”是指执行重新排序操作。

DukeMTMC REID：根据表 3，我们的 MGN 架构在具有挑战性的 DukeMTMC-REID 数据集上也表现出色。gp-re id[2]是一个很好的实践，它结合了许多有用的策略，并取得了最好的结果。MGN 的排名为 1/map=88.7%/78.4%，比 gp-reid 的排名高出 3.5%，在 map 中高出 5.6%。站在目前最具挑战性的数据集的这一性能水平上，我们认为对于进一步完善的深 Re-ID 系统，仍有一些问题需要克服。

CUHK03: 如表 4所示，我们的MGN在cuhk03标记设置上达到等级1/map=68.0%/67.4%，在 cuhk03 检测设置上达到等级 66.8%/66.0%，大大超过了所有公布的结果。在这里，我们可以观察到标记和检测条件的结果之间存在明显的差距。我们认为，它反映了检测失败对人的 REID 性能的重要影响，强调了高性能行人检测器的重要性。

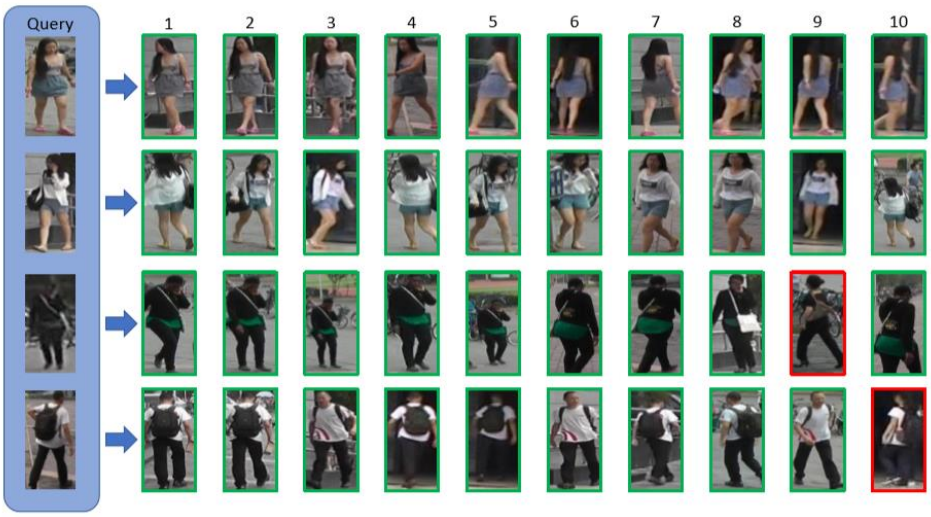

图 4 按 MGN 列出的 Market-1501 数据集上某些查询图像的排名前 10 位的列表。检索到的图像都来自图库集中，但不是来自同一个相机视角。带有绿色边框的图像与给定查询属于同一标识，而带有红色边框的图像与给定查询不属于同一标识。

Methods	Rank-1	mAP
SVDNet[35]	76.7	56.8
AOS[16]	79.2	62.1
HA-CNN[22]	80.5	63.8
GSRW[29]	80.7	66.4
DuATM[31]	81.8	64.6
PCB+RPP[36]	83.3	69.2
PSE+ECN[27]	84.5	75.7
DNN_CRF[5]	84.9	69.5
GP-reid[2]	85.2	72.8
MGN(Ours)	**88.7**	**78.4**

表 3 DukeMTMC RE-ID 结果比较

Methods	Labeled		Detected	
	Rank-1	mAP	Rank-1	mAP
BOW+XQDA[46]	7.9	7.3	6.4	6.4
LOMO+XQDA[23]	14.8	13.6	12.8	11.5
IDE[47]	22.2	21.0	21.3	19.7
PAN[48]	36.9	35.0	36.3	34.0
SVDNet[35]	40.9	37.8	41.5	37.3
HA-CNN[22]	44.4	41.0	41.7	38.6
MLFN[4]	54.7	49.2	52.8	47.8
PCB+RPP[36]	-	-	63.7	57.5
MGN(Ours)	**68.0**	**67.4**	**66.8**	**66.0**

表 4 采用 CUHK03 测试协议的结果比较

4.4 组件的有效性

为了验证 MGN 中每个组件的有效性，我们在单查询模式下对 Market-1501 数据集进行了多个不同组件设置的消融实验。请注意，每个比较实验中的其他不相关设置与第 4.1 节中的 MGN 实现相同，我们已经仔细调整了所有候选模型，并用我们的设置报告了最佳性能。表 5 显示了与 MGN 组件相关的不同设置下的比较结果。我们分别对每个组成部分进行如下分析：

MGN vs ResNet-50：MGN 与 resnet-50 比较基线 resnet-50 模型与我们的 MGN 模型的结果，我们可以观察到 MGN 在以下方面有显著的性能改进：等 rank-1/MAP=87.5%/71.4%至 95.3%/86.2%（+7.8%/14.8%）。我们也在用与 MGN 具有相似权重的 resnet-101 模型进行相同的实验。更深入的 resnet-101 网络确实带来了相当大的性能提升（+2.9%/7.4%），但与我们的 MGN 模型仍有很大的差距，这表明来自其他分支的额外权重不是改进的主要贡献者，而是精心设计的网络架构。结果表明，本文提出的 MGN 具有令人难以置信的人脸特征表示能力。

Multiple Branch vs Multiple Networks：在一个网络中的多分支集合与多个独立网络的集合非常相似，但是我们相信多分支的合作比集合学习能获得更好的性能。我们分别训练三个独立的 resnet-50 网络，每个网络分别复制 MGN 中三个分支的对应配置，即全局分支、第 2 部分分支和第 3 部分分支。在实验中，我们从两个方面探讨了多分支体系结构的影响。一方面，从全局的角度，我们比较了 MGN 和三个单网络合奏的性能。集成策略确实比

结果表明，分支机构之间的协作学习到的特征表示比独立网络更具歧视性。另一方面，从局部的角度，我们分别比较了在相应的分支设置下，MGN 子分支与单网络所学习到的特征的性能。正如我们所期望的，分支机构的功能也比单个网络的性能更好。我们认为，分支机构之间的相互作用补充了他们个人学习过程中的盲点。

Multi-branch architecture settings：多分支深层网络体系结构对于行人重识别任务非常常见[8]。我们提出的 MGN 通过学习多粒度表示的能力超越了所有以前的体系结构。基于我们提出的体系结构，我们可以直观地推断出许多不同的体系结构。一方面，基于 MGN 模型，我们可以增加或减少本地分支的数量。将模型中删除的第 3 部分分支与添加的第 4 部分分支进行比较，发现删除第 3 部分分支（mgn w/o part-3）会导致性能明显下降，其等级为 1/map=0.9%/0.7%，添加第 4 部分分支（mgn w/part-4）不会带来明显的性能提升。这证实了我们提出的三分支设置的必要性和效率。另一方面，对于部分逻辑分支，分区数是影响学习表示粒度的超参数。我们交替地将每个局部分支中的特征映射分为 2、3、4 个部分，仍然发现建议的第 2 部分/第 3 部分设置是最佳的。第 2 部分/第 4 部分的设置跳过了第 3 部分的粒度级别，并导致性能降级（按等级 1/map=0.9%/1.3%），这表明了第 3 部分粒度的重要性。对比第 2 部分/第 4 部分设置与第 3 部分/第 4 部分设置的结果，前者比后者造成更大的性能损失。原因是 2 和 4 的均匀划分不会在条纹之间引入重叠区域，但第 3 部分/第 4 部分设置会。我们认为这种重叠可以引入不同分区之间的相关性，从中可以学习更多的可辨别的本地信息。

Triplet Loss：许多以前的工作[3，8，20，43]已经证明了联合训练的有效性，其中包括对分类的 Softmax 损失和对个人识别任务中度量学习的 **Triplet Loss**。在我们的实验中，我们用 resnet-50 和 mgn 模型重现了增强效应。在所有候选数据集的 **Triplet Loss** 的帮助下，我们可以观察到基线模型的+1.2%/3.6% /图改进，以及 mgn 模型的+0.4%/0.7%秩-1/图改进。我们可以从改进的数据中观察到两个有趣的影响：1）地图的改进比排名 1 的准确性更明显，这证明了度量学习损失的排名效应。2）**Triplet Loss** 对基线模型的影响大于对 MGN 的影响。与 SoftMax 损失相比，**Triplet Loss** 有助于捕获更详细的信息，以满足边际条件[28]。我们提出的网络结构最初是为了增强局部代表性，这稀释了 **Triplet Loss** 的原始影响。请注意，在没

有 **Triplet Loss** 设置（mgn w/o tp）的 mgn 中，我们在 2048 Dim 功能上不使用 SoftMax 损耗，或者在减少的 256 Dim 功能上使用 SoftMax 损耗。

Feature response with multiple granularity，我们坚持我们提出的 MGN 模型学习具有多个粒度级别的全局和局部特征表示。图 5 显示了一些输入行人图像的特征响应图，这些图像是从 mgn 中所有分支的顶部提取的。所有的响应图都过滤了大部分复杂的背景，这些背景不包含行人身份的有用信息。局部分支的响应主要集中在身体的主要部位，而四肢、腰或脚的信息通常被忽略。在局部分支，对主体的全局响应丢失，但更多地集中在某些特定的部分。例如，在第 2 部分案例中，我们可以观察身体部位（如肩膀和关节）的偏好。至于第三部分的案例，答案更分散在身体部位，但一些关键的语义信息是首选。请注意，在最后一张行人图像的第 3 部分响应图上，我们可以观察到该行人胸部前面的亮圆形区域。这是他的 T 恤的一个标志，这可以被视为一个非常歧视他的身份特征。

Model	Rank-1	Rank-5	Rank-10	mAP
ResNet-50	87.5	94.9	96.7	71.4
ResNet-101	90.4	95.7	97.2	78.0
ResNet-50+TP	88.7	96.0	97.2	75.0
Global (Branch)	89.8	95.8	97.5	78.5
Part-2 (Single)	92.6	97.1	98.0	80.2
Part-2 (Branch)	94.4	97.9	98.8	83.9
Part-3 (Single)	93.1	97.6	98.7	82.1
Part-3 (Branch)	94.4	98.2	98.8	84.1
G+P2+P3 (Single)	94.4	97.6	98.5	85.2
MGN w/o Part-3	94.4	97.9	98.7	85.7
MGN w/ Part-4	95.1	98.3	98.9	86.1
MGN (Part2+4)	94.8	98.2	98.9	85.6
MGN (Part3+4)	95.0	98.1	98.8	86.1
MGN w/o TP	95.3	97.9	98.7	86.2
MGN	**95.7**	**98.3**	**99.0**	**86.9**

表 5 在 Market-1501 数据集上不同设置的结果

图 5 从每个分支的输出布局中提取特征响应图

5 总结

本文提出了一种新的多分支深度网络多粒度网络（MGN），用于学习行人再识别任务中的特征表示。MGN 中的每个分支学习具有身体分割的特定粒度的全局或局部表示。我们的方法直接学习水平分割特征条上的局部特征，它是完全端到端的，不引入区域建议或姿态估计等零件定位操作。大量实验表明，该方法不仅在多个主流行人重识别数据集上取得了最新的效果，而且与现有方法相比，将性能提升到了一个最高的水平。

6 REFERENCES

[1] Ejaz Ahmed, Michael Jones, and Tim K Marks. 2015. An improved deep learning architecture for person re-identification. In *CVPR*. 3908–3916.

[2] Jon Almazan, Bojana Gajic, Naila Murray, and Diane Larlus. 2018. Re-ID done right: towards good practices for person re-identification. *arXiv preprint arXiv:1801.05339* (2018).

[3] Xiang Bai, Mingkun Yang, Tengteng Huang, Zhiyong Dou, Rui Yu, and Yongchao Xu. 2017. Deep-Person: Learning Discriminative Deep Features for Person Re- Identification. *arXiv preprint arXiv:1711.10658* (2017).

[4] Xiaobin Chang, Timothy M. Hospedales, and Tao Xiang. 2018. Multi-Level Factorisation Net for Person Re-Identification. In *CVPR*. 2109–2118.

[5] Dapeng Chen, Dan Xu, Hongsheng Li, Nicu Sebe, and Xiaogang Wang. 2018. Group Consistent Similarity Learning via Deep CRF for Person Re-Identification. In *CVPR*. 8649–8658.

[6] Weihua Chen, Xiaotang Chen, Jianguo Zhang, and Kaiqi Huang. 2017. Beyond triplet loss: a deep quadruplet network for person re-identification. In *CVPR*. 403–412.

[7] Yanbei Chen, Xiatian Zhu, and Shaogang Gong. 2017. Person Re-Identification by Deep Learning Multi-Scale Representations. In *ICCV*. 2590–2600.

[8] De Cheng, Yihong Gong, Sanping Zhou, Jinjun Wang, and Nanning Zheng. 2016. Person re-identification by multi-channel parts-based cnn with improved triplet loss function. In *CVPR*. 1335–1344.

[9] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. 2009. Imagenet: A large-scale hierarchical image database. In *CVPR*. 248–255.

[10] Pedro Felzenszwalb, David McAllester, and Deva Ramanan. 2008. A discrimina- tively trained, multiscale, deformable part model. In *CVPR*. 1–8.

[11] Ross Girshick. 2015. Fast r-cnn. In *ICCV*. 1440–1448.

[12] Raia Hadsell, Sumit Chopra, and Yann LeCun. 2006. Dimensionality reduction by learning an invariant mapping. In *CVPR*, Vol. 2. 1735–1742.

[13] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2016. Deep residual learning for image recognition. In *CVPR*. 770–778.

[14] Alexander Hermans, Lucas Beyer, and Bastian Leibe. 2017. In defense of the triplet loss for person re-identification. *arXiv preprint arXiv:1703.07737* (2017).

[15] Elad Hoffer and Nir Ailon. 2015. Deep metric learning using triplet network. *International Workshop on Similarity-Based Pattern Recognition*. Springer, 84–92.

[16] Houjing Huang, Dangwei Li, Zhang Zhang, Xiaotang Chen, and Kaiqi Huang. 2018. Adversarially Occluded Samples for Person Re-Identification. In *CVPR*. 5098–5107.

[17] Sergey Ioffe and Christian Szegedy. 2015. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *ICML*. 448–456.

[18] Max Jaderberg, Karen Simonyan, Andrew Zisserman, et al. 2015. Spatial trans- former networks. In *NIPS*. 2017–2025.

[19] Dangwei Li, Xiaotang Chen, Zhang Zhang, and Kaiqi Huang. 2017. Learning deep context-aware features over body and latent parts for

person re-identification. In *CVPR*. 384–393.

[20] Wei Li, Rui Zhao, Tong Xiao, and Xiaogang Wang. 2014. Deepreid: Deep filter pairing neural network for person re-identification. In *CVPR*. 152–159.

[21] Wei Li, Xiatian Zhu, and Shaogang Gong. 2017. Person re-identification by deep joint learning of multi-loss classification. In *IJCAI*. 2194–2200.

[22] Wei Li, Xiatian Zhu, and Shaogang Gong. 2018. Harmonious Attention Network for Person Re-Identification. In *CVPR*. 2285–2294.

[23] Shengcai Liao, Yang Hu, Xiangyu Zhu, and Stan Z Li. 2015. Person re- identification by local maximal occurrence representation and metric learning. In *CVPR*. 2197–2206.

[24] Hao Liu, Jiashi Feng, Meibin Qi, Jianguo Jiang, and Shuicheng Yan. 2017. End-to- end comparative attention networks for person re-identification. *IEEE Transac- tions on Image Processing* 26, 7 (2017), 3492–3506.

[25] Xihui Liu, Haiyu Zhao, Maoqing Tian, Lu Sheng, Jing Shao, Shuai Yi, Junjie Yan, and Xiaogang Wang. 2017. HydraPlus-Net: Attentive Deep Features for Pedestrian Analysis. In *CVPR*. 350–359.

[26] Ergys Ristani, Francesco Solera, Roger Zou, Rita Cucchiara, and Carlo Tomasi. 2016. Performance Measures and a Data Set for Multi-Target, Multi-Camera Tracking. In *ECCV workshop on Benchmarking Multi-Target Tracking*. 17–35.

[27] M. Saquib Sarfraz, Arne Schumann, Andreas Eberle, and Rainer Stiefelhagen. 2018. A Pose-Sensitive Embedding for Person Re-Identification With Expanded Cross Neighborhood Re-Ranking. In *CVPR*. 420–429.

[28] Florian Schroff, Dmitry Kalenichenko, and James Philbin. 2015. Facenet: A unified embedding for face recognition and clustering. In *CVPR*. 815–823.

[29] Yantao Shen, Hongsheng Li, Tong Xiao, Shuai Yi, Dapeng Chen, and Xiaogang Wang. 2018. Deep Group-Shuffling Random Walk for Person Re-Identification. In *CVPR*. 2265–2274.

[30] Yantao Shen, Tong Xiao, Hongsheng Li, Shuai Yi, and Xiaogang Wang. 2018. End-to-End Deep Kronecker-Product Matching for Person Re-Identification. In *CVPR*. 6886–6895.

[31] Jianlou Si, Honggang Zhang, Chun-Guang Li, Jason Kuen, Xiangfei Kong, Alex C. Kot, and Gang Wang. 2018. Dual Attention Matching Network for Context-Aware Feature Sequence Based Person Re-Identification. In *CVPR*. 5363–5372.

[32] Hyun Oh Song, Yu Xiang, Stefanie Jegelka, and Silvio Savarese. 2016. Deep metric learning via lifted structured feature embedding. In *CVPR*. 4004–4012.

[33] Chi Su, Jianing Li, Shiliang Zhang, Junliang Xing, Wen Gao, and Qi Tian. 2017. Pose-driven Deep Convolutional Model for Person Re-identification. In *ICCV*. 3980–3989.

[34] Yi Sun, Xiaogang Wang, and Xiaoou Tang. 2015. Deeply learned face representa- tions are sparse, selective, and robust. In *CVPR*. 2892–2900.

[35] Yifan Sun, Liang Zheng, Weijian Deng, and Shengjin Wang. 2017. SVDNet for Pedestrian Retrieval. In *ICCV*. 2590–2600.

[36] Yifan Sun, Liang Zheng, Yi Yang, Qi Tian, and Shengjin Wang. 2018. Beyond Part Models: Person Retrieval with Refined Part Pooling. In *ECCV*. In press.

[37] Rahul Rama Varior, Mrinal Haloi, and Gang Wang. 2016. Gated siamese con- volutional neural network architecture for human re-identification. In *ECCV*. Springer, 791–808.

[38] Feng Wang, Xiang Xiang, Jian Cheng, and Alan Loddon Yuille. 2017. Normface: l2 hypersphere embedding for face verification. In *2017 ACM on Multimedia Conference*. 1041–1049.

[39] Tong Xiao, Hongsheng Li, Wanli Ouyang, and Xiaogang Wang. 2016. Learn- ing deep feature representations with domain guided dropout for person re- identification. In *CVPR*. 1249–1258.

[40] Jing Xu, Rui Zhao, Feng Zhu, Huaming Wang, and Wanli Ouyang. 2018. Attention- Aware Compositional Network for Person Re-Identification. In *CVPR*. 2119–2128.

[41] Hantao Yao, Shiliang Zhang, Yongdong Zhang, Jintao Li, and Qi Tian. 2017. Deep representation learning with part loss for person re-identification. *arXiv preprint arXiv:1707.00798* (2017).

[42] Dong Yi, Zhen Lei, Shengcai Liao, and Stan Z Li. 2014. Deep metric learning for person re-identification. In *ICPR*. 34–39.

[43] Xuan Zhang, Hao Luo, Xing Fan, Weilai Xiang, Yixiao Sun, Qiqi Xiao, Wei Jiang, Chi Zhang, and Jian Sun. 2017. Alignedreid: Surpassing human-level performance in person re-identification. *arXiv preprint arXiv:1711.08184* (2017).

[44] Haiyu Zhao, Maoqing Tian, Shuyang Sun, Jing Shao, Junjie Yan, Shuai Yi, Xi- aogang Wang, and Xiaoou Tang. 2017. Spindle net: Person re-identification with human body region guided feature decomposition and fusion. In *CVPR*. 1077–1085.

[45] Liming Zhao, Xi Li, Jingdong Wang, and Yueting Zhuang. 2017. Deeply-learned part-aligned representations for person re-identification. In *ICCV*. 3219–3228.

[46] Liang Zheng, Liyue Shen, Lu Tian, Shengjin Wang, Jingdong Wang, and Qi Tian. 2015. Scalable Person Re-identification: A Benchmark. In *ICCV*. 1116–1124.

[47] Liang Zheng, Yi Yang, and Alexander G Hauptmann. 2016. Person re- identification: Past, present and future. *arXiv preprint arXiv:1610.02984* (2016).

[48] Zhedong Zheng, Liang Zheng, and Yi Yang. 2017. Pedestrian alignment network for large-scale person re-identification. *arXiv preprint arXiv:1707.00408* (2017).

[49] Zhedong Zheng, Liang Zheng, and Yi Yang. 2017. Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro. In *ICCV*. 3774– 3782.

[50] Zhun Zhong, Liang Zheng, Donglin Cao, and Shaozi Li. 2017. Re-ranking person re-identification with k-reciprocal encoding. In *CVPR*. 3652–3661.